

RAPPORT DE TP

Module : Fouille de données

Sujet : Amélioration de l'algorithme Apriori

Adaptation automatique du seuil MinSup

Réalisé par :

Matricule :

Enseignant :

Année universitaire : 2025 - 2026

1 Introduction

L'algorithme Apriori est une méthode classique de fouille de données pour l'extraction de règles d'association. Son efficacité dépend fortement du choix du support minimum (MinSup), car ce paramètre agit directement sur le nombre de candidats générés et sur l'élagage de l'espace de recherche.

Dans l'approche classique, MinSup est fixé manuellement par l'utilisateur. Ce choix peut être arbitraire : un seuil trop faible produit beaucoup de patterns et un grand nombre de règles parfois peu utiles ; un seuil trop élevé peut au contraire faire disparaître des associations pertinentes.

L'objectif de ce travail est de proposer une amélioration simple, visible et facile à défendre oralement : remplacer le MinSup fixe par un MinSup dynamique calculé à partir de la densité du jeu de données. Le seuil de confiance (MinConf) est volontairement laissé fixe afin d'isoler clairement l'effet de cette amélioration sur Apriori.

2 Méthodologie : l'approche améliorée

2.1 Jeu de données utilisé

Les expérimentations ont été réalisées sur le fichier cancer_poumon.csv contenant 276 transactions et 16 attributs nominaux. Après conversion transactionnelle, le jeu contient 34 items distincts.

Chaque transaction représente une ligne du tableau, et chaque valeur nominale est considérée comme un item. Le jeu utilisé est déjà discrétisé et encodé sous forme lisible, ce qui facilite directement l'application d'Apriori.

2.2 Calcul dynamique du MinSup

L'amélioration proposée consiste à calculer automatiquement le support minimum à partir de la densité moyenne des transactions :

$$\text{MinSup}_{\text{dyn}} = \text{moyenne_longueur_transactions} / \text{nombre_items_uniques}$$

Afin d'éviter des valeurs extrêmes, ce seuil est ensuite borné dans l'intervalle [0.05 ; 0.30].

Dans notre dataset, la longueur moyenne des transactions est 16.0, le nombre d'items uniques est 34, ce qui donne une valeur brute de 0.471. Après bornage, le seuil dynamique retenu est $\text{MinSup} = 0.30$.

2.3 MinConf fixé pour préserver la clarté

Le seuil de confiance est maintenu fixe à $\text{MinConf} = 0.60$. Ce choix permet de ne modifier qu'un seul levier de l'algorithme et de montrer clairement que le gain observé provient de l'adaptation automatique du support.

Cette décision est cohérente avec la théorie d'Apriori : le support intervient pendant la génération et l'élagage des itemsets fréquents, tandis que la confiance sert surtout au filtrage final des règles.

3 Analyse des résultats et comparaison

3.1 Comparaison quantitative

La comparaison a été effectuée entre une version classique (MinSup = 0.20) et la version améliorée (MinSup dynamique = 0.30). Dans les deux cas, MinConf = 0.60 et un filtrage par lift > 1.10 est appliqué pour conserver des règles statistiquement intéressantes.

Métrique	Approche Classique	Approche Améliorée	Variation
Nombre de patterns	1172	225	-80.8%
Nombre de règles	2856	261	-90.9%
Support moyen	0.240	0.349	45.4%
Confiance moyenne	0.746	0.735	-1.4%
Lift moyen	1.389	1.274	-8.3%
Candidats testés	3048	807	-73.5%

On observe que l'augmentation contrôlée du support minimum réduit fortement le volume des motifs extraits. Le nombre de patterns passe de 1172 à 225 et le nombre de règles de 2856 à 261. En contrepartie, le support moyen des règles conservées augmente nettement, ce qui indique que les règles retenues sont plus fréquentes et moins bruitées.

3.2 Analyse de l'efficacité computationnelle

Le gain le plus important concerne le coût de calcul. En moyenne sur plusieurs exécutions, le temps passe de 1.837 s pour l'approche classique à 0.196 s pour l'approche améliorée.

Cela correspond à un gain de temps de 89.3%. Cette amélioration provient directement du fait qu'un support plus élevé élimine très tôt une grande partie des candidats non pertinents.

Autrement dit, le MinSup dynamique agit comme un mécanisme de pruning adaptatif : il ajuste automatiquement le niveau d'exigence au dataset sans modifier la logique fondamentale de l'algorithme Apriori.

4 Visualisation et qualité des règles

Figure 1. Impact du MinSup dynamique sur la réduction du nombre de candidats, de patterns et de règles.





Figure 2. Répartition des règles dans l'espace support / confiance.



Le nuage de points montre que les règles issues de la version améliorée se concentrent dans des zones de support plus élevé. Le volume total de règles est plus faible, mais leur fréquence moyenne est meilleure, ce qui facilite l'interprétation.

Par exemple, parmi les meilleures règles extraites par la version améliorée, on trouve : "Anxiete=Oui et CancerPoumon=Oui -> DifficulteAvaler=Oui et DoigtsJaunes=Oui" avec un support de 0.304, une confiance de 0.672 et un lift de 1.912. Ce type de règle montre que l'approche améliorée conserve des associations cohérentes tout en supprimant une grande partie du bruit combinatoire.

5 Conclusion

L'approche améliorée proposée dans ce travail reste volontairement simple : elle ne modifie qu'un seul paramètre clé d'Apriori, le support minimum. Cette simplicité constitue précisément sa force pédagogique, car l'effet de l'amélioration est immédiatement visible sur le nombre de candidats testés, le volume des patterns, le nombre de règles et le temps d'exécution.

Sur le dataset cancer_poumon.csv, le MinSup dynamique fixé automatiquement à 0.30 permet de réduire de 80.8% le nombre de patterns, de 90.9% le nombre de règles et d'environ 89.3% le temps moyen d'exécution, tout en augmentant le support moyen des règles extraites.

Ainsi, ce travail montre qu'une amélioration simple et directement liée à la propriété anti-monotone d'Apriori peut déjà produire un gain important. Pour des travaux futurs, cette idée pourrait être complétée par un encodage plus avancé des données, une comparaison avec d'autres algorithmes de règles d'association ou l'étude d'un MinConf variable dans une phase expérimentale séparée.